

MnemoBench：评估长生命周期记忆系统的 信念更新、抗自污染与遗忘能力

Nemos 研究*

项目地址：<https://github.com/mmlong818/nemos>

2026 年 8 月

摘要

面向大语言模型（LLM）智能体的持久记忆层，通常以**召回**为评测标准：系统能否检索回先前说过的内容？我们主张，在长期使用中，主导性的失败模式并非召回，而是**维护**：(1) 当事实发生变化时未能修正旧信念；(2) 让智能体自己生成或想象的内容污染用户的事实库；(3) 从不遗忘，使陈旧琐碎信息随时间拉低检索精度。我们提出 **MnemoBench**——一个可复现的评测基准，含三类任务，恰好针对上述行为，且真值由生成器预先固定，而非事后判定。我们据此评测 Nemos：一个具备双时间矛盾失效、用户事实与智能体自述之间命名空间隔离、以及 FSRs 风格遗忘衰减的可嵌入记忆内核。在信念更新上，矛盾失效将旧值泄漏率从 80.0% 降到 **34.0%**，但伴随一定的召回代价（更新准确率 92.0 → 76.0%），由此暴露出一个精度/召回的可调旋钮；我们进一步表明，较早的词法矛盾检测器会漏判“属性替换”型更新，而语义检测器能将其捕回（泄漏 50.0 → **34.0%**）。命名空间隔离将自污染率从 96.8% 降到 **1.6%**，且不损召回。遗忘衰减将陈旧琐碎泄漏从 100.0% 压到 **16.4%**，同时保留重要事实。我们开源 MnemoBench 及全部评测代码。

1 引言

面向 LLM 智能体的记忆系统（如 MemGPT/Letta [4]、mem0 [1]、Zep/Graphiti [5, 9]）通常以多会话问答来评测，例如 LoCoMo [2] 与 LongMemEval [7]，它们主要考察检索。然而真正侵蚀长期助手可信度的失败却另有其因：

- **信念陈旧**。某事实变化了（工作、城市、饮食、感情状态），系统却仍把旧值当作现状反复给出——近期关于记忆系统中知识更新的研究指出，这既常见又棘手 [6]。
- **自污染**。在陪伴/智能体场景中，模型会产出第一人称或推测性内容；一旦被错误归因，便进入用户档案，日后被当作用户自身的权威事实返回。

*工作草稿。三个合成任务族各含 $n=50$ 条样本；探针总数不同，LongMemEval 外部交叉锚点含 $n=30$ 个问题。冻结结果的来源记录于 `bench/results/manifest.json`。

- **从不遗忘。** 仅追加 (append-only) 的存储会不断累积一次性琐碎, 挤占重要事实、拉低检索精度。

我们做两点贡献: (i) **MnemoBench**, 以生成器固定真值的方式隔离上述三种行为 (§4); (ii) 对 **Nemos** 记忆内核的评测 (§3), 表明每个机制都对应一处可消融、可度量的改进 (§6), 其中包含我们在矛盾检测器中发现并修复的一处真实缺陷的 before/after 对照。

2 相关工作

记忆架构。 MemGPT/Letta [4]、mem0 [1]、Zep/Graphiti 的时序知识图谱 [5, 9]。区别在于: 分层分离、显式的失效语义、来源权威性把关。

时序/双时间建模。 Graphiti 用边的有效区间 [9]; Nemos 在每条记忆上物化世界时间与系统时间的有效性字段。

遗忘。 FSRS / 间隔重复的可提取性模型 [8, 3], 被用于机器记忆而非人类复习排程。

评测基准。 LoCoMo [2] 与 LongMemEval [7] 均以召回为中心。与本文主张最接近的是 Uddin 等人的同期工作 [6]: 其 *Memora* 基准与 Forgetting-Aware Memory Accuracy (FAMA) 指标显式惩罚对过时/失效记忆的依赖, 印证了“从召回转向维护”的转变。MnemoBench 与之互补: 不汇总成单一总分, 而是通过单机制消融分别隔离每个维护机制 (失效、隔离、衰减), 并额外给出一处真实检测器修复的 before/after。

3 Nemos 记忆内核

Nemos 是一个可嵌入的记忆内核。此处只描述受测的机制。

3.1 分层记忆与来源权威性

五层 (episodic、semantic、personal_semantic、procedural、archival)。每条记录带 `source.authoritative` (用户陈述 vs. 模型推断); 推断内容被禁止进入权威的个人事实 (不变量 I4)。

3.2 双时间矛盾失效

记录带世界轴 (`valid_at/invalid_at`) 与系统轴 (`created_at/expired_at`) 时间戳, 以及 `belief_state` $\in$ {active, invalidated, superseded, corrected}。在离线反思中, 与现有 `personal_semantic` 锚点矛盾的新事实会把旧条目标为 `invalidated`; 默认检索只返回 `active` 记录。

一处真实缺陷：词法 vs. 语义检测。 较早的检测器用字符二元组 (bigram) Jaccard 相似度对矛盾候选做粗筛。它能可靠捕获强否定 (“离开了 Google”), 却漏判属性替换——当新值与旧值在词法上不相似时 (素食 → 鱼素)。我们用 embedding 余弦的候选检索替换该粗筛, 并在现有个人事实上增加一道 “同属性、互斥” 的对账 (reconciliation)。§6 量化了其 before/after。

3.3 命名空间隔离 (抗自污染)

用户事实存于 `forUser(uid)`; 智能体自述存于 `forUser(persona:pid)`——一个物理上独立的键空间。检索用户事实时不可能浮现人格内容。

3.4 FSRS 风格的遗忘衰减

每条记录有稳定度 S 与可提取性 $R = \exp(-\Delta t/S)$ ——这是 FSRS 风格间隔重复记忆的一个简化指数变体 (难度参数保留在 schema 中, 但更新规则尚未使用)。访问会强化 S ; 当 R 低于冷却阈值、近期零访问、且超过休眠窗口时, 记录被标为 cold 并从默认检索中隐藏 (archival 永不冷却)。

4 MnemoBench

4.1 设计原则

真值由生成器固定: 每条样本的事实脚本 (哪个属性、取哪些值、按何顺序; 哪些人格陈述是陷阱) 先行确定, 再渲染为自然语言会话。评分将记忆质量与生成质量解耦: 一个 LLM 评判器只检视被检索出的记录集合, 判断期望事实是否在内、是否有被禁 (陈旧/泄漏) 事实被当作现状呈现; 评判器从不撰写最终答案。

4.2 任务族

BUC ——信念更新与矛盾。 某单值用户属性在多会话中变化 1–3 次; 探针询问当前值。指标为更新准确率 (期望值在内) 与旧值泄漏率 (某旧值被当作现状; 越低越好)。

ASP ——抗自污染。 用户陈述与人格自述交错, 其中若干被刻意构造成貌似可信的陷阱。探针查询用户事实。指标为污染率 (人格虚构被当作用户权威事实返回; 越低越好) 与用户事实召回。

FOR ——遗忘与显著性。 持久重要事实与较旧时间戳的一次性琐碎混合; 显著事实在保留期内被重访。指标为琐碎泄漏 (已冷却的琐碎仍浮现; 越低越好) 与重要事实保留率 (护栏; 须保持高位)。

4.3 样本格式与评分

每条样本是一段 JSON：含有序的 sessions (`{speaker, text, contentDate?}`) 与一个或多个 probes (`{query, expected[], forbidden[]}`)。三个任务的标签均由事实脚本确定性派生，因此标签不会与所渲染的叙述发生漂移：BUC 中最后一个脚本值是唯一的当前 `expected`，更早的值均为 `forbidden`；ASP 中 `expected` 是脚本中的用户事实，`forbidden` 是每条陷阱的误归因蒸馏——若把该人格陈述误归因于用户会形成的那条假事实（若改用陷阱的完整原句，评判器会因话题重叠产生可测量的误报，虚增污染率）；FOR 中 `expected` 是脚本中的重要事实，`forbidden` 是全部脚本琐事条目。评判器收到查询、`expected` 与 `forbidden` 列表、以及检索到的记录集合，返回两个布尔值——`contains_expected` 与 `contains_forbidden`；若某记录显式将被禁值标注为“过去”，则不计为泄漏。

5 实验设置

2026 年 6–7 月冻结跑批中，所有系统的抽取/反思均用 OpenAI `gpt-4o`，嵌入用 `text-embedding-3-small`；评判器为 `gpt-4o`。这些是历史跑批标识，不是当前模型推荐；替换任一模型都应视为一次新的、不可直接横比的实验。每个合成任务报告 $n = 50$ 条样本。记忆系统一侧在瞬时错误重试全部失败后按空检索计分（其全部探针记为 `miss`，与外部基线路径一致）；评判器调用重试全部失败则将该探针从比率中剔除并单独上报（冻结跑批中此类失败为零）。每个任务只改变一个具名机制，并保持本地 runner 配置不变；观测差异是在此冻结设置下与该机制一致的证据，不是可外推的普遍因果估计：

- BUC：语义（当前配置）vs. 词法（较早配置）vs. 关闭失效。
- ASP：命名空间隔离 vs. 共享存储。
- FOR：开启衰减 vs. 关闭衰减。为隔离衰减，两侧均关闭反思，并取冷却阈值 0.3、休眠 0、保留期 120 天；重要事实在保留期内被访问（建模“显著事实会被重访”）。

作为一个外部参照点，我们用相同模型与相同评判器在 BUC 上运行 `mem0 (v2.0.8)`。作为标准基准的交叉锚点，我们另在 LongMemEval [7] 的知识更新子集（oracle 设定）上评测一个 30 题的切片，沿用其“先生成再评判”的问答准确率方法学，并消融失效（语义 vs. 关闭）。

6 结果

信念更新 (BUC)。 旧值泄漏沿消融阶梯单调下降：关闭失效 80.0%，较早的词法检测器 50.0%，语义检测器 **34.0%**——矛盾机制把旧值答案削减了一半以上；而仅词法 → 语义这一改动，又通过捕获词法粗筛漏掉的属性替换更新，再去掉约三分之一的泄漏。该收益并非免费：更新准确率从

¹`mem0 v2.0.8`，相同的 `gpt-4o + text-embedding-3-small`，由相同评判器评分。

表 1: 信念更新 (BUC)。SLR 越低越好; UA 为召回护栏。

系统	更新准确率 (%)	旧值泄漏率 (%)
mem0 (外部) ¹	96.0	82.0
关闭失效 (下界)	92.0	80.0
词法检测器 (较早配置)	84.0	50.0
语义检测器 (受测配置)	76.0	34.0

表 2: 抗自污染 (ASP) 与遗忘 (FOR)。

<i>ASP</i> —— 污染率 / 用户事实召回 (%)		
共享存储 (基线)	96.8	96.0
命名空间隔离	1.6	97.2
<i>FOR</i> —— 琐碎泄漏 / 重要事实保留 (%)		
关闭衰减	100.0	98.6
开启衰减	16.4	97.9

92.0% (下界) 降到 76.0% (语义), 即激进失效偶尔会把仍然有效的事实也退役掉。因此 BUC 暴露出另两个任务所没有的精度/召回旋钮; 我们认为其工作点是可调的 (候选相似度阈值、对账保守度), 而非固定。外部系统 mem0 会把被矛盾的事实与其替代值同时保留为 active (它只追加而不失效旧值), 使其泄漏接近“关闭失效”的下界。

外部交叉锚点 (LongMemEval)。 同样的效应也出现在标准基准上: 在 LongMemEval 知识更新子集的 30 题切片上 (问答准确率, 先生成再评判), 开启语义失效把准确率从 33.3% 提升到 **43.3%**——这 +10 个百分点完全归因于失效消融。其绝对水平不高 (Nemos 在此是对 oracle 证据会话从零构建记忆, 且未针对 LongMemEval 做任何调优), 故我们读差值而非绝对值: 即便在以召回为主的外部数据上, 信念维护也有帮助。

抗自污染 (ASP)。 这是最大、最干净的效应。在 250 个用户事实探针上, 命名空间隔离把污染率从 96.8% (单一共享存储, 正如仅追加式设计) 降到 **1.6%**——约 60 倍的下降——而用户事实召回在统计上不变 (96.0% vs. 97.2%)。把智能体自述的键空间与用户事实物理隔开, 几乎消除了这一失败模式, 且不损召回。

遗忘 (FOR)。 在 146 个显著性探针上, 衰减把琐碎泄漏从 100.0% 压到 **16.4%**, 而重要事实保留率不变 (98.6% vs. 97.9%): 未被重访的琐碎被冷却出默认检索, 而被重访的重要事实不丢失。

7 讨论与局限

对 LLM 评判器的依赖。 渲染与评分都用 LLM；我们以集合成员式评判器（不生成答案）、低温度、并辅以人工抽检来缓解。

合成数据。 样本为合成；我们只在相同数据下报告相对差异，并加入一个标准基准切片（Long-MemEval）作为交叉锚点。

冻结实现快照。 本文只报告 `bench/results/manifest.json` 所列的已提交评测产物。后续 SDK 版本加入了结构化事实对账和更广的召回改进；这些变化不会被悄悄并入本文表格，必须通过新的 benchmark 版本重新评测。

FOR 的隔离选择。 关闭反思并采用较激进的衰减参数，能干净地隔离衰减，但并不代表完整系统的默认配置；我们已显式说明。

残余泄漏。 语义检测器在生成的困难样本上（值对在词法与语义上都很接近）未能将旧值泄漏降到零；其 BUC 的召回代价（UA 92.0 $\rightarrow$ 76.0%）表明该工作点应当随用例调整。

8 结论

长生命周期的记忆应当以维护而非仅以召回来评判。MnemoBench 将这一主张操作化，而 Nemos 的每个维护机制都带来可消融、可度量的增益。

参考文献

- [1] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready AI agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025.
- [2] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. *arXiv preprint arXiv:2402.17753*, 2024.
- [3] Open Spaced Repetition. Free spaced repetition scheduler (FSRS). <https://github.com/open-spaced-repetition/fsrs4anki>, 2023. Open-source spaced-repetition scheduler based on a DSR-style Difficulty–Stability–Retrievability memory-state model; see also [8].
- [4] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. MemGPT: Towards LLMs as operating systems. *arXiv preprint arXiv:2310.08560*, 2023.

- [5] Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. *arXiv preprint arXiv:2501.13956*, 2025.
- [6] Md Nayem Uddin, Kumar Shubham, Eduardo Blanco, Chitta Baral, and Gengyu Wang. From recall to forgetting: Benchmarking long-term memory for personalized agents. *arXiv preprint arXiv:2604.20006*, 2026. Introduces the Memora benchmark and the Forgetting-Aware Memory Accuracy (FAMA) metric.
- [7] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. Long-MemEval: Benchmarking chat assistants on long-term interactive memory. *arXiv preprint arXiv:2410.10813*, 2024.
- [8] Junyao Ye, Jingyong Su, and Yilong Cao. A stochastic shortest path algorithm for optimizing spaced repetition scheduling. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*, pages 4381–4390, 2022. DSR (Difficulty–Stability–Retrievability) memory model underlying FSRS.
- [9] Zep AI. Graphiti: Build real-time knowledge graphs for AI agents. <https://github.com/getzep/graphiti>, 2024. Open-source temporal knowledge-graph engine underlying Zep.