

MnemoBench：评估长生命周期记忆系统的 信念更新、抗自污染与遗忘能力

Nemos 创始团队*

2026

摘要

面向大语言模型（LLM）智能体的持久记忆层，通常以**召回**为评测标准：系统能否检索回先前说过的内容？我们主张，在长期使用中，主导性的失败模式并非召回，而是**维护**：(1) 当事实发生变化时未能修正旧信念；(2) 让智能体自己生成或想象的内容污染用户的事实库；(3) 从不遗忘，使陈旧琐碎信息随时间拉低检索精度。我们提出 **MnemoBench**——一个可复现的评测基准，含三类任务，恰好针对上述行为，且真值由生成器预先固定，而非事后判定。我们据此评测 Nemos：一个具备双时间矛盾失效、用户事实与智能体自述之间命名空间隔离、以及基于 FSRs 的遗忘衰减的可嵌入记忆内核。在信念更新上，矛盾失效将旧值泄漏率从 80.0% 降到 **34.0%**，但伴随一定的召回代价（更新准确率 $92.0 \rightarrow 76.0\%$ ），由此暴露出一个精度/召回的可调旋钮；我们进一步表明，已发布的词法矛盾检测器会漏判“属性替换”型更新，而语义检测器能将其捕回（泄漏 $50.0 \rightarrow 34.0\%$ ）。命名空间隔离将自污染率从 71.2% 降到 **1.6%**，且无损召回。遗忘衰减将陈旧琐碎泄漏从 96.0% 压到 **17.4%**，同时保留重要事实。我们开源 MnemoBench 及全部评测代码。

1 引言

面向 LLM 智能体的记忆系统（如 MemGPT/Letta [4]、mem0 [1]、Zep/Graphiti [5]）通常以多会话问答来评测，例如 LOCOMO [2] 与 LongMemEval [6]，它们主要考察检索。然而真正侵蚀长期助手可信度的失败却另有其因：

- **信念陈旧**。某事实变化了（工作、城市、饮食、感情状态），系统却仍把旧值当作现状反复给出——近期关于记忆系统中知识更新的研究指出，这既常见又棘手。
- **自污染**。在陪伴/智能体场景中，模型会产出第一人称或推测性内容；一旦被错误归因，便进入用户档案，日后被当作用户自身的权威事实返回。
- **从不遗忘**。仅追加（append-only）的存储会不断累积一次性琐碎，挤占重要事实、拉低检索精度。

*工作草稿。所报告的全部数字均来自随附评测框架中冻结的 $n=50$ 实验运行。

我们做两点贡献：(i) **MnemoBench**，以生成器固定真值的方式隔离上述三种行为 (§4)；(ii) 对 **Nemos** 记忆内核的评测 (§3)，表明每个机制都对应一处可消融、可度量的改进 (§6)，其中包含我们在矛盾检测器中发现并修复的一处真实缺陷的 before/after 对照。

2 相关工作

记忆架构。 MemGPT/Letta [4]、mem0 [1]、Zep/Graphiti 的时序知识图谱 [5]。区别在于：分层分离、显式的失效语义、来源权威性把关。

时序/双时间建模。 Graphiti 用边的有效区间；Nemos 采用事件溯源式失效，并物化为扁平字段供热路径查询。

遗忘。 FSRS / 间隔重复的可提取性模型 [3]，被用于机器记忆而非人类复习排程。

评测基准。 LOCOMO [2]、LongMemEval [6] 均以召回为中心；MnemoBench 以维护为中心，二者互补。

3 Nemos 记忆内核

Nemos 是一个可嵌入的记忆内核。此处只描述受测的机制。

3.1 分层记忆与来源权威性

五层(episodic、semantic、personal_semantic、procedural、archival)。每条记录带 `source.authoritative` (用户陈述 vs. 模型推断)；推断内容被禁止进入权威的个人事实 (不变量 I4)。

3.2 双时间矛盾失效

记录带世界轴 (`valid_at/invalid_at`) 与系统轴 (`created_at/expired_at`) 时间戳，以及 `belief_state` $\in \{\text{active, invalidated, superseded, corrected}\}$ 。在离线反思中，与现有 `personal_semantic` 锚点矛盾的新事实会把旧条目标为 `invalidated`；默认检索只返回 `active` 记录。

一处真实缺陷：词法 vs. 语义检测。 已发布的检测器用字符二元组 (bigram) Jaccard 相似度对矛盾候选做粗筛。它能可靠捕获强否定 (“离开了 Google”)，却漏判属性替换——当新值与旧值在词法上不相似时 (素食 $\rightarrow$ 鱼素)。我们用 embedding 余弦的候选检索替换该粗筛，并在现有个人事实上增加一道“同属性、互斥”的对账 (reconciliation)。§6 量化了其 before/after。

3.3 命名空间隔离（抗自污染）

用户事实存于 `forUser(uid)`；智能体自述存于 `forUser(persona:pid)`——一个物理上独立的键空间。检索用户事实时不可能浮现人格内容。

3.4 FSRS 遗忘衰减

每条记录有稳定度 S 、难度 D 、可提取性 $R = \exp(-\Delta t/S)$ 。访问会强化 S ；当 R 低于冷却阈值、近期零访问、且超过休眠窗口时，记录被标为 `cold` 并从默认检索中隐藏（archival 永不冷却）。

4 MnemoBench

4.1 设计原则

真值由生成器固定：每条样本的事实脚本（哪个属性、取哪些值、按何顺序；哪些人格陈述是陷阱）先行确定，再渲染为自然语言会话。评分将记忆质量与生成质量解耦：一个 LLM 评判器只检视被检索出的记录集合，判断期望事实是否在内、是否有被禁（陈旧/泄漏）事实被当作现状呈现；评判器从不撰写最终答案。

4.2 任务族

BUC ——信念更新与矛盾。 某单值用户属性在多会话中变化 1–3 次；探针询问当前值。指标为更新准确率（期望值在内）与旧值泄漏率（某旧值被当作现状；越低越好）。

ASP ——抗自污染。 用户陈述与人格自述交错，其中若干被刻意构造成貌似可信的陷阱。探针查询用户事实。指标为污染率（人格虚构被当作用户权威事实返回；越低越好）与用户事实召回。

FOR ——遗忘与显著性。 持久重要事实与较旧时间戳的一次性琐碎混合；显著事实在保留期内被重访。指标为琐碎泄漏（已冷却的琐碎仍浮现；越低越好）与重要事实保留率（护栏；须保持高位）。

4.3 样本格式与评分

每条样本是一段 JSON：含有序的 `sessions` (`{speaker, text, contentDate?}`) 与一个或多个 `probes` (`{query, expected[], forbidden[]}`)。对 BUC，标签由事实脚本确定性派生（最后一个值是唯一的当前 `expected`，更早的值均为 `forbidden`），因此标签不会与所渲染的叙述发生漂移。评判器收到查询、`expected` 与 `forbidden` 列表、以及检索到的记录集合，返回两个布尔值——`contains_expected` 与 `contains_forbidden`；若某记录显式将被禁值标注为“过去”，则不计为泄漏。

表 1: 信念更新 (BUC)。SLR 越低越好; UA 为召回护栏。

系统	更新准确率 (%)	旧值泄漏率 (%)
mem0 (外部) ¹	96.0	82.0
关闭失效 (下界)	92.0	80.0
词法检测器 (已发布)	84.0	50.0
语义检测器 (本工作)	76.0	34.0

表 2: 抗自污染 (ASP) 与遗忘 (FOR)。

<i>ASP</i> —— 污染率 / 用户事实召回 (%)		
共享存储 (基线)	71.2	92.0
命名空间隔离	1.6	92.4
<i>FOR</i> —— 琐碎泄漏 / 重要事实保留 (%)		
关闭衰减	96.0	73.8
开启衰减	17.4	75.2

5 实验设置

所有系统的抽取/反思均用 OpenAI gpt-4o, 嵌入用 text-embedding-3-small; 评判器为 gpt-4o。每个任务报告 $n = 50$ 条样本。每个任务恰好消融受测的那一个机制, 从而任何差异都可归因于该机制:

- BUC: 语义 (完整) vs. 词法 (已发布) vs. 关闭失效。
- ASP: 命名空间隔离 vs. 共享存储。
- FOR: 开启衰减 vs. 关闭衰减。为隔离衰减, 两侧均关闭反思, 并取冷却阈值 0.3、休眠 0、保留期 120 天; 重要事实在保留期内被访问 (建模 “显著事实会被重访”)。

作为一个外部参照点, 我们用相同模型与相同评判器在 BUC 上运行 mem0 (v2.0.8)。作为标准基准的交叉锚点, 我们另在 LongMemEval [6] 的知识更新子集 (oracle 设定) 上评测一个 30 题的切片, 沿用其 “先生成再评判” 的问答准确率方法学, 并消融失效 (语义 vs. 关闭)。

6 结果

信念更新 (BUC)。 旧值泄漏沿消融阶梯单调下降: 关闭失效 80.0%, 已发布词法检测器 50.0%, 语义检测器 **34.0%**——矛盾机制把旧值答案削减了一半以上; 而仅词法 → 语义这一改动, 又通过

¹mem0 v2.0.8, 相同的 gpt-4o + text-embedding-3-small, 由相同评判器评分。

捕获词法粗筛漏掉的属性替换更新，再去掉约三分之一的泄漏。该收益并非免费：更新准确率从 92.0%（下界）降到 76.0%（语义），即激进失效偶尔会把仍然有效的事实也退役掉。因此 BUC 暴露出另两个任务所没有的精度/召回旋钮；我们认为其工作点是可调的（候选相似度阈值、对账保守度），而非固定。外部系统 mem0 会把被矛盾的事实与其替代值同时保留为 active（它只追加而不失效旧值），使其泄漏接近“关闭失效”的下界。

外部交叉锚点 (LongMemEval)。 同样的效应也出现在标准基准上：在 LongMemEval 知识更新子集的 30 题切片上（问答准确率，先生成再评判），开启语义失效把准确率从 33.3% 提升到 **43.3%**——这 +10 个百分点完全归因于失效消融。其绝对水平不高（Nemos 在此是对 oracle 证据会话从零构建记忆，且未针对 LongMemEval 做任何调优），故我们读差值而非绝对值：即便在以召回为主的外部数据上，信念维护也有帮助。

抗自污染 (ASP)。 这是最大、最干净的效应。在 250 个用户事实探针上，命名空间隔离把污染率从 71.2%（单一共享存储，正如仅追加式设计）降到 **1.6%**——约 44 倍的下降——而用户事实召回在统计上不变（92.0% vs. 92.4%）。把智能体自述的键空间与用户事实物理隔开，几乎消除了这一失败模式，且不损召回。

遗忘 (FOR)。 在 149 个显著性探针上，衰减把琐碎泄漏从 96.0% 压到 **17.4%**，而重要事实保留率不变（73.8% vs. 75.2%）：未被重访的琐碎被冷却出默认检索，而被重访的重要事实不丢失。

7 讨论与局限

对 LLM 评判器的依赖。 渲染与评分都用 LLM；我们以集合成员式评判器（不生成答案）、低温度、并辅以人工抽检来缓解。

合成数据。 样本为合成；我们只在相同数据下报告相对差异，并加入一个标准基准切片（LongMemEval）作为交叉锚点。

FOR 的隔离选择。 关闭反思并采用较激进的衰减参数，能干净地隔离衰减，但并不代表完整系统的默认配置；我们已显式说明。

残余泄漏。 语义检测器在生成的困难样本上（值对在词法与语义上都很接近）未能将旧值泄漏降到零；其 BUC 的召回代价（UA 92.0 → 76.0%）表明该工作点应当随用例调整。

8 结论

长生命周期的记忆应当以维护而非仅以召回来评判。MnemoBench 将这一主张操作化，而 Nemos 的每个维护机制都带来可消融、可度量的增益。

参考文献

- [1] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready AI agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025.
- [2] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. *arXiv preprint arXiv:2402.17753*, 2024.
- [3] Open Spaced Repetition. Free spaced repetition scheduler (FSRS): a modern spaced-repetition algorithm based on the DSR (difficulty, stability, retrievability) memory model. <https://github.com/open-spaced-repetition/fsrs4anki>, 2023.
- [4] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. MemGPT: Towards LLMs as operating systems. *arXiv preprint arXiv:2310.08560*, 2023.
- [5] Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. *arXiv preprint arXiv:2501.13956*, 2025. Powered by the Graphiti temporal knowledge-graph engine.
- [6] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. Long-MemEval: Benchmarking chat assistants on long-term interactive memory. *arXiv preprint arXiv:2410.10813*, 2024.